

Исследование стартапов

Автор проекта: **Егоров Д.Д.**

Введение

Знакомство с проектом:

Финансовая компания, работающая с венчурными инвестициями, хочет понять закономерности финансирования стартапов и оценить перспективы выхода на рынок с покупкой и развитием компаний. Для этого необходимо провести исследование на исторических данных. Необходимо проанализировать информацию о компаниях, объёмах и типах привлечённых инвестиций, а также дополнительную статистику по возвратам средств.

Задача проекта:

Подготовить датасет к работе, исследовать динамику и структуру финансирования стартапов и ответить на вопросы, важные для оценки инвестиционных стратегий.

В рамках проекта предстоит выполнить следующие шаги:

- Провести предобработку данных, убрать дубликаты и пропуски, проверить корректность числовых и временных значений.
- Выделить группы компаний по срокам финансирования и сравнить их по количеству и объёму инвестиций.
- Классифицировать сегменты рынка на массовые, средние и нишевые и учесть это в дальнейшем анализе.
- Определить типичные и аномальные значения объёмов финансирования, исключить выбросы и ограничить период исследования.
- Сравнить популярность и объёмы разных типов финансирования.
- Проанализировать динамику раундов и объёмов инвестиций по годам, а также изменения в массовых сегментах рынка.
- Рассчитать долю возврата средств для разных типов финансирования и оценить её устойчивость.
- Подвести итоговые выводы и дать рекомендации, куда и каким образом было бы целесообразно инвестировать, если бы на дворе был 2015 год.

Шаг 1. Знакомство с данными: загрузка и предобработка

Датасет получен из базы данных стартапов.

Название основного датасета — `cb_investments.zip` . Внутри архива один файл — `cb_investments.csv` . Он содержит информацию о компаниях и состоявшемся финансировании.

Описание данных `cb_investments.csv` :

- `name` — название компании.
- `homepage_url` — ссылка на сайт компании.
- `category_list` — категории, в которых работает компания. Указываются через `|` .
- `market` — основной рынок или отрасль компании.
- `funding_total_usd` — общий объём привлечённых инвестиций в долларах США.
- `status` — текущий статус компании, например `operating` , `closed` и так далее.
- `country_code` — код страны, например `USA`.
- `state_code` — код штата или региона, например, `CA`.
- `region` — регион, например, `SF Bay Area`.
- `city` — город, в котором расположена компания.
- `funding_rounds` — общее число раундов финансирования.
- `participants` — число участников в раундах финансирования.
- `founded_at` — дата основания компании.
- `founded_month` — месяц основания в формате `YYYY-MM` .
- `founded_quarter` — квартал основания в формате `YYYY-QN` .
- `founded_year` — год основания.
- `first_funding_at` — дата первого финансирования.
- `mid_funding_at` — дата среднего по времени раунда финансирования.
- `last_funding_at` — дата последнего финансирования.
- `seed` — сумма инвестиций на посевной стадии.
- `venture` — сумма венчурных инвестиций.
- `equity_crowdfunding` — сумма, привлечённая через долевого краудфандинг.
- `undisclosed` — сумма финансирования нераскрытого типа.
- `convertible_note` — сумма инвестиций через конвертируемые займы.
- `debt_financing` — сумма долгового финансирования.
- `angel` — сумма инвестиций от бизнес-ангелов.
- `grant` — сумма полученных грантов.
- `private_equity` — сумма инвестиций в виде прямых (частных) вложений.
- `post_ipo_equity` — сумма финансирования после IPO.
- `post_ipo_debt` — сумма долгового финансирования после IPO.
- `secondary_market` — сумма сделок на вторичном рынке.
- `product_crowdfunding` — сумма, привлечённая через продуктовый краудфандинг.
- `round_A` — `round_N` — сумма инвестиций в соответствующем раунде.

Название дополнительного датасета — `cb_returns.csv` . Он содержит суммы

возвратов по типам финансирования в миллионах долларов по годам.

Описание данных `cb_returns.csv` :

- `year` — год возврата средств.
- `seed` — сумма возвратов от посевных инвестиций.
- `venture` — сумма возвратов от венчурных инвестиций.
- `equity_crowdfunding` — сумма, возвращённая по долевым краудфандингу.
- `undisclosed` — сумма возвратов нераскрытого типа.
- `convertible_note` — сумма возвратов через конвертируемые займы.
- `debt_financing` — сумма возвратов от долгового финансирования.
- `angel` — сумма возвратов бизнес-ангелам.
- `grant` — сумма возвратов по грантам.
- `private_equity` — сумма возвратов прямых (частных) вложений.
- `post_ipo_equity` — сумма возвратов от IPO.
- `post_ipo_debt` — сумма возвратов от долгового IPO.
- `secondary_market` — сумма возвратов от сделок на вторичном рынке.
- `product_crowdfunding` — сумма возвратов по продуктовому краудфандингу.

Файлы находятся в папке `datasets` , если вы выполняете работу на платформе. В случае, если вы делаете работу локально, доступ к файлам в папке можно получить по адресу <https://code.s3.yandex.net/datasets/> + имя файла.

1.1. Вывод общей информации

Начнём с загрузки библиотек и датасетов **`cb_investments.csv`** (взятый из `cb_investments.zip`) и **`cb_returns.csv`**. Будем использовать **`pandas`** и дополнительные библиотеки визуализации данных, такие как **`matplotlib (pyplot и ticker)`**, **`seaborn`**, **`phik`** а также **`missingno`**. Данные датасетов сохраним в двух переменных: `inv_df` и `rtn_df` .

```
In [1]: # Импортируем все необходимые библиотеки
try:
    import pandas as pd
    import matplotlib.pyplot as plt
    import matplotlib.ticker as ticker
    import seaborn as sns
    import phik
    import missingno as msn
except ImportError:
    !pip install pandas matplotlib seaborn phik missingno
    import pandas as pd
    import matplotlib.pyplot as plt
    import matplotlib.ticker as ticker
    import seaborn as sns
    import phik
    import missingno as msno
```

```
In [2]: # Выгружаем данные в переменные inv_df и ret_df
inv_df = pd.read_csv("https://code.s3.yandex.net/datasets/cb_investments.zip", sep=
rtn_df = pd.read_csv('https://code.s3.yandex.net/datasets/cb_returns.csv')
```

Познакомимся с данными обоих датасетов — выведем общую информацию и первые строки созданных датафреймов методами `info()` и `head()`, а также посчитаем пропуски и визуализируем их через библиотеку `missingno`.

==== ДАННЫЕ О ДАТАФРЕЙМЕ INVESTMENTS ====

```
In [3]: # Выводим общую информацию и первые 10 строк датафрейма investments
inv_df.info()
inv_df.head(10)
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 54294 entries, 0 to 54293
Data columns (total 40 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   name                                  49437 non-null  object
1   homepage_url                         45989 non-null  object
2   category_list                        45477 non-null  object
3   market                              45477 non-null  object
4   funding_total_usd                   49438 non-null  object
5   status                               48124 non-null  object
6   country_code                        44165 non-null  object
7   state_code                          30161 non-null  object
8   region                              44165 non-null  object
9   city                                43322 non-null  object
10  funding_rounds                       49438 non-null  float64
11  participants                         30473 non-null  float64
12  founded_at                           38554 non-null  object
13  founded_month                        38482 non-null  object
14  founded_quarter                      38482 non-null  object
15  founded_year                         38554 non-null  float64
16  first_funding_at                    49438 non-null  object
17  mid_funding_at                      30288 non-null  object
18  last_funding_at                     49438 non-null  object
19  seed                                49438 non-null  float64
20  venture                             49438 non-null  float64
21  equity_crowdfunding                 49438 non-null  float64
22  undisclosed                         49438 non-null  float64
23  convertible_note                    49438 non-null  float64
24  debt_financing                      49438 non-null  float64
25  angel                              49438 non-null  float64
26  grant                               49438 non-null  float64
27  private_equity                      49438 non-null  float64
28  post_ipo_equity                     49438 non-null  float64
29  post_ipo_debt                       49438 non-null  float64
30  secondary_market                    49438 non-null  float64
31  product_crowdfunding                49438 non-null  float64
32  round_A                             49438 non-null  float64
33  round_B                             49438 non-null  float64
34  round_C                             49438 non-null  float64
35  round_D                             49438 non-null  float64
36  round_E                             49438 non-null  float64
37  round_F                             49438 non-null  float64
38  round_G                             49438 non-null  float64
39  round_H                             49438 non-null  float64
dtypes: float64(24), object(16)
memory usage: 16.6+ MB

```

Out[3]:

	name	homepage_url	category_list	market	funding_total_usd	status
0	Harvard University	http://harvard.edu	[Education]	Education	9,00,00,000	operating
1	University of New Brunswick	http://www.unb.ca	NaN	NaN	20,00,000	operating
2	DuPont	http://www.dupont.com	[Business Services] [Agriculture] [Automotive] Inve...	Business Services	90,00,000	operating
3	University of Michigan	http://www.umich.edu/	[Education]	Education	77,00,000	operating
4	Case Western Reserve University	http://www.case.edu	[Education]	Education	5,40,000	operating
5	Xavier University	http://www.xavier.edu/	NaN	NaN	1,90,00,000	operating
6	Tulane University	http://tulane.edu/	[Education]	Education	1,20,00,000	operating
7	Duke University	http://www.duke.edu	[Education]	Education	87,00,000	operating
8	Virginia Commonwealth University, Richmond	http://www.vcu.edu/	NaN	NaN	60,00,000	operating
9	WeGame	http://www.WeGame.com	[Social Media]	Social Media	35,00,000	acquired

10 rows × 40 columns


```
In [4]: # Считаем и выводим долю пропущенных значений в каждом столбце датафрейма investmen
print(f'Доля пропущенных значений по столбцам:\n{(inv_df.isna().sum() / inv_df.shap

# Визуализируем состояние датафрейма investments через библиотеку missingno
msn.bar(inv_df)
plt.title('Заполненность данных в inv_df до предобработки', fontsize=14)
plt.show()
```

Доля пропущенных значений по столбцам:

name	8.95%
homepage_url	15.3%
category_list	16.24%
market	16.24%
funding_total_usd	8.94%
status	11.36%
country_code	18.66%
state_code	44.45%
region	18.66%
city	20.21%
funding_rounds	8.94%
participants	43.87%
founded_at	28.99%
founded_month	29.12%
founded_quarter	29.12%
founded_year	28.99%
first_funding_at	8.94%
mid_funding_at	44.21%
last_funding_at	8.94%
seed	8.94%
venture	8.94%
equity_crowdfunding	8.94%
undisclosed	8.94%
convertible_note	8.94%
debt_financing	8.94%
angel	8.94%
grant	8.94%
private_equity	8.94%
post_ipo_equity	8.94%
post_ipo_debt	8.94%
secondary_market	8.94%
product_crowdfunding	8.94%
round_A	8.94%
round_B	8.94%
round_C	8.94%
round_D	8.94%
round_E	8.94%
round_F	8.94%
round_G	8.94%
round_H	8.94%

dtype: object



Датасет `cb_investments.csv` содержит **40 столбцов** и **54294 строк**, в которых представлена информация о компаниях и состоявшемся финансировании.

После первичного анализа данных можно сделать следующие выводы:

- Названия столбцов уже приведены к удобному для работы формату `snake_case`, поэтому менять их не требуется.
- В выводе `.info()` заметно, что перед названиями столбцов `market` и `funding_total_usd` стоят пробелы. Их необходимо будет обработать, иначе это будет вызывать ошибки при обращении к этим столбцам по имени.
- В столбце `category_list` значения указаны через символ `"|"`. Это может вызвать ошибки при обработке данных, поэтому содержимое данного столбца, скорее всего, придётся переделать в более удобный вид.
- Данные датасета представлены двумя типами - **object** и **float64**. Для большей части столбцов используется правильный тип данных. Неправильный тип данных выбран для следующего списка столбцов:
 - `funding_total_usd` — необходимо перевести из **object** во **float64**
 - `participants` — необходимо перевести из **float64** в **Int64**
 - `funding_rounds` — необходимо перевести из **float64** в **Int64**
 - `founded_at` — необходимо перевести из **object** в **datetime64**
 - `founded_month` и `founded_quarter` — необходимо вычлени из `founded_at` (содержащим полную дату) и сохранить в **datetime64**
 - `founded_year` — необходимо перевести из **float64** в **datetime64**
 - `first_funding_at` — необходимо перевести из **object** в **datetime64**
 - `mid_funding_at` — необходимо перевести из **object** в **datetime64**
 - `last_funding_at` — необходимо перевести из **object** в **datetime64**

Касательно пропусков:

- Пропуски в данных имеют неоднородный характер. Так, 2/3 датафрейма состоит из столбцов, в которых пропущено ровно 8.94–8.95% данных. Это очевидно не является совпадением и указывает на то, что в датасете около 4856 полностью пустых (или практически пустых) строк. Причина появления этих пропусков скорее всего техническая (например ошибка при выгрузке или объединении таблиц). Данные строки желательно удалить на этапе предобработки данных.
- Пропуски в столбцах `founded_at`, `founded_month`, `founded_quarter` и `founded_year` (доля пропусков от 28.99% до 29.12%) могут быть связаны с отсутствием исторической справки для ряда компаний.
- Пропуски в столбцах `city` (20.21%), а также `region` и `country_code` (18.66%) могли появиться как из-за технической ошибки, так и из-за намеренного сокрытия этой информации первоначальным источником.
- Пропуски в столбце `state_code` (44.45%) скорее всего появились из-за географической специфики. Маркер штата обычно является обязательным и понятным для компаний из США или Австралии, но для европейских, азиатских или российских компаний это поле часто игнорируется при заполнении или вовсе не предусмотрено в интерфейсе сбора данных.
- Пропуски в столбце `participants` (43.87%) могут быть связаны с тем, что бизнес-сделки часто являются непубличными.
- Пропуски в `mid_funding_at` (44.21%) предположительно связаны с тем, что дата среднего по времени раунда финансирования вычисляется только если у компании было 3 и более таких раундов. Если у компании был менее 3 раундов, «середина» либо совпадает с краями, либо не имеет смысла. Пропуски здесь — признак молодых компаний или тех, кто закрылся после первых инвестиций.

==== ДАННЫЕ О ДАТАФРЕЙМЕ RETURNS ====

```
In [5]: # Выводим общую информацию и первые 10 строк датафрейма returns
rtn_df.info()
rtn_df.head(10)
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 15 entries, 0 to 14
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   year                                  15 non-null     int64
1   seed                                  15 non-null     float64
2   venture                              15 non-null     float64
3   equity_crowdfunding                  15 non-null     float64
4   undisclosed                          15 non-null     float64
5   convertible_note                    15 non-null     float64
6   debt_financing                      15 non-null     float64
7   angel                               15 non-null     float64
8   grant                               15 non-null     float64
9   private_equity                      15 non-null     float64
10  post_ipo_equity                     15 non-null     float64
11  post_ipo_debt                       15 non-null     float64
12  secondary_market                    15 non-null     float64
13  product_crowdfunding                15 non-null     float64
dtypes: float64(13), int64(1)
memory usage: 1.8 KB

```

```

Out[5]:

```

	year	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt_financi
0	2000	16.70	55.40	0.00	78.21	0.00	8.
1	2001	2.88	23.49	0.00	21.50	0.01	4.
2	2002	6.59	209.42	0.00	25.77	0.02	3.
3	2003	7.74	233.86	0.00	9.40	0.01	1.
4	2004	9.93	555.90	0.00	33.19	0.01	13.
5	2005	26.60	2628.92	0.00	9.51	0.02	35.
6	2006	61.81	3100.18	0.19	46.74	1.78	113.
7	2007	70.41	3585.37	0.01	55.37	3.22	125.
8	2008	89.72	2717.02	0.03	41.02	1.71	397.
9	2009	160.21	2501.29	0.18	37.50	2.25	394.

```

In [6]: # Считаем и выводим долю пропущенных значений в каждом столбце датафрейма returns
print(f'Доля пропущенных значений по столбцам:\n{(rtn_df.isna().sum() / rtn_df.shape[0]).to_dict()}')


# Визуализируем состояние датафрейма returns через библиотеку missingno
msn.bar(rtn_df)
plt.show()

```

Доля пропущенных значений по столбцам:

year	0.0%
seed	0.0%
venture	0.0%
equity_crowdfunding	0.0%
undisclosed	0.0%
convertible_note	0.0%
debt_financing	0.0%
angel	0.0%
grant	0.0%
private_equity	0.0%
post_ipo_equity	0.0%
post_ipo_debt	0.0%
secondary_market	0.0%
product_crowdfunding	0.0%

dtype: object



Датасет `cb_returns.csv` содержит **14 столбцов** и **15 строк**, в которых представлена информация об объёмах возвратов по годам и типам финансирования в миллионах долларов.

После первичного анализа данных можно сделать следующие выводы:

- Названия столбцов уже приведены к удобному для работы формату `snake_case`, поэтому менять их не требуется.
- Типы данных подобраны верно. Столбец `year` имеет тип **int64** (что логично для года), а все остальные столбцы с финансовыми показателями — **float64** (что необходимо для денежных сумм).
- В данных полностью отсутствуют пропуски.
- Финансовые показатели указаны в сокращённом формате (в миллионах долларов) — на это стоит обратить внимание при сравнении данных между двумя датасетами, так как в `cb_investments.csv` суммы были указаны полностью. Для удобства, рекомендуется привести финансовые показатели из датасета `cb_returns.csv` в

аналогичный формат, умножив все значения на 1000000.

Промежуточные выводы

Перед дальнейшим анализом данных, необходимо учесть следующие моменты:

- Два выделенных датафрейма не следует объединять в один. Во-первых, потому что они имеют разный уровень детализации. `inv_df` — это микроданные, где каждая строка — это отдельная компания. `rtn_df` — это макроданные, где каждая строка — это итог по всему рынку за целый год. Если попытаться объединить их по году, то это продублирует рыночные показатели для каждой компании этого года, что не даст новой информации о самой компании, но раздует таблицу. Во-вторых, у них отсутствует общий ключ. В датафрейме `rtn_df` нет названий компаний или ID, а значит мы не можем узнать, сколько вернула конкретная фирма. Частичная связь возможна только по столбцу `year`, но даты в двух таблицах не соотносятся напрямую и такое объединение приведёт только к большей путанице. Вместо объединения в одну таблицу, датафреймы следует использовать для сопоставительного анализа, как два независимых источника.
- Датафрейм `inv_df` нуждается в обязательной предобработке данных:
 - преобразование имён столбцов, содержащих лишние пробелы;
 - удаление пустых строк;
 - изменение типов данных ряда столбцов.

1.2. Предобработка данных

Приступим к предобработке данных. Начнём с датафрейма `inv_df`.

```
In [7]: # Очистка названий столбцов от лишних пробелов
inv_df.columns = inv_df.columns.str.strip()

# Удаление строк где отсутствует название компании (так как они не пригодны для ана.
inv_df = inv_df.dropna(subset=['name']).copy()

# Удаление полных дубликатов
inv_df = inv_df.drop_duplicates()

# Обработка текстовых пропусков
# (заполняем пропуски в ключевых текстовых полях заглушкой 'unknown')
text_columns_fix = ['homepage_url', 'market', 'country_code', 'state_code', 'region']
for col in text_columns_fix:
    inv_df[col] = inv_df[col].replace('-', 'unknown').fillna('unknown')

# Обработка столбца category_list
# (избавляемся от пустых значений и дефисов а также создаём в ячейках данного столб
inv_df['category_list'] = inv_df['category_list'].replace('-', 'Other')
inv_df['category_list'] = inv_df['category_list'].fillna('Other').str.split('|')
```

```

# Обработка столбца market
# (избавляемся от лишних пробелов)
inv_df['market'] = inv_df['market'].str.strip()

# Обработка столбца funding_total_usd
# (убираем лишние символы и удаляем пустые строки)
inv_df['funding_total_usd'] = pd.to_numeric(
    inv_df['funding_total_usd'].astype(str).str.replace(r'^\d.', '', regex=True),
    errors='coerce'
)
inv_df = inv_df.dropna(subset=['funding_total_usd'])

# Обработка столбцов participants и funding_rounds
for col in ['participants', 'funding_rounds']:
    inv_df[col] = pd.to_numeric(inv_df[col], errors='coerce').astype('Int64')

```

```

In [8]: # Обработка столбцов с датами
date_cols = ['founded_at', 'first_funding_at', 'mid_funding_at', 'last_funding_at']

for col in date_cols:
    # Принудительно приводим всё к строке и убираем лишние пробелы по краям
    # Конвертируем в дату
    # Всё, что не похоже на дату автоматически превратится в NaT (пустоту для дат)
    inv_df[col] = pd.to_datetime(inv_df[col].astype(str).str.strip(), errors='coerce')

# Удаляем строки, где нет даты первого или последнего финансирования
inv_df = inv_df.dropna(subset=['first_funding_at', 'last_funding_at'])

# Заполнение пропусков в столбце mid_funding_at на основании первой и последней дат
# (создаем фильтр (mask), который отбирает только те компании, которые подходят под
# mid_funding_at.isna() – средняя дата пустая;
# first_funding_at.notna() – есть первая дата;
# last_funding_at.notna() – есть последняя дата;)
mask = (inv_df['mid_funding_at'].isna()) & \
        (inv_df['first_funding_at'].notna()) & \
        (inv_df['last_funding_at'].notna())

# Вычисление середины интервала
inv_df.loc[mask, 'mid_funding_at'] = inv_df.loc[mask, 'first_funding_at'] + \
    (inv_df.loc[mask, 'last_funding_at'] - inv_df.loc[mask, 'first_funding_at']) / 2

# Формирование производных даты
inv_df['founded_month'] = inv_df['founded_at'].dt.to_period('M').dt.to_timestamp()
inv_df['founded_quarter'] = inv_df['founded_at'].dt.to_period('Q').dt.to_timestamp()
inv_df['founded_year'] = inv_df['founded_at'].dt.to_period('Y').dt.to_timestamp()

```

```

In [9]: # Подсчёт оставшихся пропусков в столбце mid_funding_at
print(f"Итоговое количество пропусков в столбце mid_funding_at: {inv_df['mid_funding_at'].isna().sum()}")

print("Обновлённая информация о датафрейме inv_df:")
inv_df.info()
inv_df.head(10)

```

Итоговое количество пропусков в столбце mid_funding_at: 0

Обновлённая информация о датафрейме inv_df:

<class 'pandas.core.frame.DataFrame'>

Index: 40904 entries, 0 to 49437

Data columns (total 40 columns):

#	Column	Non-Null Count	Dtype
0	name	40904 non-null	object
1	homepage_url	40904 non-null	object
2	category_list	40904 non-null	object
3	market	40904 non-null	object
4	funding_total_usd	40904 non-null	float64
5	status	40904 non-null	object
6	country_code	40904 non-null	object
7	state_code	40904 non-null	object
8	region	40904 non-null	object
9	city	40904 non-null	object
10	funding_rounds	40904 non-null	Int64
11	participants	27330 non-null	Int64
12	founded_at	32197 non-null	datetime64[ns]
13	founded_month	32197 non-null	datetime64[ns]
14	founded_quarter	32197 non-null	datetime64[ns]
15	founded_year	32197 non-null	datetime64[ns]
16	first_funding_at	40904 non-null	datetime64[ns]
17	mid_funding_at	40904 non-null	datetime64[ns]
18	last_funding_at	40904 non-null	datetime64[ns]
19	seed	40904 non-null	float64
20	venture	40904 non-null	float64
21	equity_crowdfunding	40904 non-null	float64
22	undisclosed	40904 non-null	float64
23	convertible_note	40904 non-null	float64
24	debt_financing	40904 non-null	float64
25	angel	40904 non-null	float64
26	grant	40904 non-null	float64
27	private_equity	40904 non-null	float64
28	post_ipo_equity	40904 non-null	float64
29	post_ipo_debt	40904 non-null	float64
30	secondary_market	40904 non-null	float64
31	product_crowdfunding	40904 non-null	float64
32	round_A	40904 non-null	float64
33	round_B	40904 non-null	float64
34	round_C	40904 non-null	float64
35	round_D	40904 non-null	float64
36	round_E	40904 non-null	float64
37	round_F	40904 non-null	float64
38	round_G	40904 non-null	float64
39	round_H	40904 non-null	float64

dtypes: Int64(2), datetime64[ns](7), float64(22), object(9)


memory usage: 12.9+ MB

Out[9]:

	name	homepage_url	category_list	market	funding_total_usd	status
0	Harvard University	http://harvard.edu	[, Education,]	Education	90000000.0	operating
1	University of New Brunswick	http://www.unb.ca	[Other]	unknown	2000000.0	operating
2	DuPont	http://www.dupont.com	[, Business Services, Agriculture, Automotive,...	Business Services	9000000.0	operating
3	University of Michigan	http://www.umich.edu/	[, Education,]	Education	7700000.0	operating
4	Case Western Reserve University	http://www.case.edu	[, Education,]	Education	540000.0	operating
5	Xavier University	http://www.xavier.edu/	[Other]	unknown	19000000.0	operating
6	Tulane University	http://tulane.edu/	[, Education,]	Education	12000000.0	operating
7	Duke University	http://www.duke.edu	[, Education,]	Education	8700000.0	operating
8	Virginia Commonwealth University, Richmond	http://www.vcu.edu/	[Other]	unknown	6000000.0	operating
9	WeGame	http://www.WeGame.com	[, Social Media,]	Social Media	3500000.0	acquired

10 rows × 40 columns

```
In [10]: plt.figure(figsize=(12, 6))
msn.bar(inv_df)
plt.title('Заполненность данных в датафрейме inv_df после предобработки', fontsize=
plt.show()
```



По итогам предобработки датафрейма `inv_df` у нас всё ещё остались пропуски в столбце `participants`, а также в столбцах с датами (`founded_at`, `founded_month`, `founded_quarter`, `founded_year`). Убедимся что в них стоят заглушки (NA для столбца `participants` и NaT для столбцов с датами), которые нужны для корректной работы используемых библиотек при обработке таких пропусков без ошибок.

```
In [11]: # Проверка пропусков в искоемых столбцах
target_cols = ['participants', 'founded_at', 'founded_month', 'founded_quarter', 'founded_year']

print("Проверка системных пропусков (NaN/NaT):")
print("-" * 30)

for col in target_cols:
    # выбираем только те строки, где в конкретном столбце пропуск (isnull)
    # и выводим 5 случайных значений (через .sample)
    print(f"Примеры из столбца {col}:")
    print(inv_df[inv_df[col].isnull()][col].sample(5, random_state=1))
    print("-" * 30)
```


Проверка системных пропусков (NaN/NaT):

```
-----  
Примеры из столбца participants:  
1188      <NA>  
47885     <NA>  
49146     <NA>  
17654     <NA>  
46387     <NA>  
Name: participants, dtype: Int64  
-----
```

```
Примеры из столбца founded_at:  
40468     NaT  
40771     NaT  
41597     NaT  
38983     NaT  
40893     NaT  
Name: founded_at, dtype: datetime64[ns]  
-----
```

```
Примеры из столбца founded_month:  
40468     NaT  
40771     NaT  
41597     NaT  
38983     NaT  
40893     NaT  
Name: founded_month, dtype: datetime64[ns]  
-----
```

```
Примеры из столбца founded_quarter:  
40468     NaT  
40771     NaT  
41597     NaT  
38983     NaT  
40893     NaT  
Name: founded_quarter, dtype: datetime64[ns]  
-----
```

```
Примеры из столбца founded_year:  
40468     NaT  
40771     NaT  
41597     NaT  
38983     NaT  
40893     NaT  
Name: founded_year, dtype: datetime64[ns]  
-----
```

Заполнять их каким-либо иным образом не нужно, так как это может исказить дальнейший анализ.

Теперь перейдём к датафрейму `rtn_df`. Так как данный датафрейм изначально был намного более компактным, и что более важно - полным, предобработка в его случае потребует минимальная.

```
In [12]: # Установка столбца year в качестве индекса  
rtn_df.set_index('year', inplace=True)  
  
# Приведение финансовых данных rtn_df к такому же виду как в inv_df
```

```

finance_cols_rtn = rtn_df.columns.difference(['year'])
rtn_df[finance_cols_rtn] *= 1000000

# Проверка результата
print("Обновлённая информация о датафрейме rtn_df:")
rtn_df.info()
rtn_df.head(10)

```

Обновлённая информация о датафрейме rtn_df:

<class 'pandas.core.frame.DataFrame'>

Index: 15 entries, 2000 to 2014

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	seed	15 non-null	float64
1	venture	15 non-null	float64
2	equity_crowdfunding	15 non-null	float64
3	undisclosed	15 non-null	float64
4	convertible_note	15 non-null	float64
5	debt_financing	15 non-null	float64
6	angel	15 non-null	float64
7	grant	15 non-null	float64
8	private_equity	15 non-null	float64
9	post_ipo_equity	15 non-null	float64
10	post_ipo_debt	15 non-null	float64
11	secondary_market	15 non-null	float64
12	product_crowdfunding	15 non-null	float64

dtypes: float64(13)

memory usage: 1.6 KB

Out[12]:

	seed	venture	equity_crowdfunding	undisclosed	convertible_note	debt
year						
2000	16700000.0	5.540000e+07	0.0	78210000.0	0.0	
2001	2880000.0	2.349000e+07	0.0	21500000.0	10000.0	
2002	6590000.0	2.094200e+08	0.0	25770000.0	20000.0	
2003	7740000.0	2.338600e+08	0.0	9400000.0	10000.0	
2004	9930000.0	5.559000e+08	0.0	33190000.0	10000.0	
2005	26600000.0	2.628920e+09	0.0	9510000.0	20000.0	
2006	61810000.0	3.100180e+09	190000.0	46740000.0	1780000.0	1
2007	70410000.0	3.585370e+09	10000.0	55370000.0	3220000.0	1
2008	89720000.0	2.717020e+09	30000.0	41020000.0	1710000.0	3
2009	160210000.0	2.501290e+09	180000.0	37500000.0	2250000.0	3

Выводы по итогам предобработки данных

1. Очистка и объем данных

- **Удаление мусора:** Из исходного датасета было отсеяно **13 390 строк** (около **24.6%**). Мы полностью избавились от технических пустых строк, дубликатов и записей без данных о финансировании.
- **Финальный актив:** Сформирован массив из **40 904 компаний**. Оптимизация типов позволила снизить потребление памяти с **16.6 МБ до 12.9 МБ**.

2. Восстановление и обработка пропусков

- **Даты финансирования:** Достигнуто **0% пропусков** в столбцах `first_funding_at`, `mid_funding_at` и `last_funding_at`. Благодаря расчету середины интервала мы получили идеальную базу для анализа сроков инвестиций.
- **Текстовые заглушки:** Пустоты в столбцах `market`, `status`, `country_code` и др. заполнены метками `'unknown'` и `'Other'`. Это позволит проводить группировку по 100% данных без потери строк.
- **Сознательные пропуски:** В столбцах `participants` и `founded_at` сохранены системные `NaN/NaT`. Это защищает итоговую статистику от искажения (например, чтобы выдуманные даты не влияли на расчет среднего возраста компаний).

3. Техническое состояние и типизация

- **Типы данных:** Все колонки переведены в корректные форматы: даты в `datetime64`, количества в `Int64`, деньги в `float64`.
- **Синхронизация таблиц:** Таблица возвратов `rtn_df` приведена к единому масштабу с инвестициями (доллары). Год установлен в качестве индекса, что упрощает навигацию и защищает временную шкалу.

Итог

Данные полностью очищены и подготовлены для выполнения задач следующего раздела.

Шаг 2. Инжиниринг признаков

При выполнении заданий не забывайте интерпретировать полученные результаты и делать промежуточные выводы.

2.1. Группы по срокам финансирования

Задача:

Разделите все компании на три группы:

- Единичное финансирование — был всего один раунд финансирования.
- Срок финансирования до года — между первым и последним раундом

финансирования прошло не более года.

- Срок финансирования более года.

Визуализируйте соотношение этих групп, создав два графика:

- По количеству компаний: Покажите, какой процент от общего числа компаний относится к каждой из трёх групп.
- По объёму инвестиций: Отобразите, какую долю от общего объёма привлечённых средств получила каждая группа.

Совет: Для ясности и согласованности используйте единую цветовую палитру для всех графиков, чтобы каждая категория (например, «Единичное финансирование») всегда отображалась одним цветом.

Код:

```
In [13]: # =====
# ==== Разделение на группы по срокам финансирования ====
# =====

# Рассчитываем продолжительность финансирования в днях
inv_df['funding_duration_days'] = (inv_df['last_funding_at'] - inv_df['first_fundin

# Определяем функцию категоризации
def categorize_funding_duration(row):
    if row['funding_rounds'] == 1:
        return 'Единичное финансирование'
    elif row['funding_duration_days'] <= 365:
        return 'Срок финансирования до года'
    else:
        return 'Срок финансирования более года'

# Создаем новый столбец 'funding_group' и применяем категоризацию
inv_df['funding_group'] = inv_df.apply(categorize_funding_duration, axis=1)

# Проверка результатов
print(inv_df['funding_group'].value_counts())

# =====
# ==== Визуализация соотношения групп ====
# =====

# Создание единой цветовой палитры для согласованности графиков
# Определение порядка групп для графиков
group_order = ['Единичное финансирование', 'Срок финансирования до года', 'Срок фин
# Цвета: синий, оранжевый, зеленый
custom_palette = {'Единичное финансирование': '#4c72b0',
                  'Срок финансирования до года': '#dd8452',
                  'Срок финансирования более года': '#55a868'}

fig, axes = plt.subplots(1, 2, figsize=(18, 7))
```

```

# График 1: По количеству компаний (процент от общего числа)
# Используем value_counts(normalize=True) * 100 для расчета процентов
group_counts_df = inv_df['funding_group'].value_counts(normalize=True).loc[group_order]
sns.barplot(
    ax=axes[0],
    x='percent',
    y='funding_group',
    data=group_counts_df,
    hue='funding_group',
    palette=custom_palette,
    order=group_order,
    legend=False
)
axes[0].set_title('Соотношение компаний по длительности финансирования (%)')
axes[0].set_xlabel('Процент компаний (%)')
axes[0].set_ylabel('')

# Добавление подписей значений на график 1
for index, value in enumerate(group_counts_df['percent']):
    axes[0].text(value + 1, index, f'{value:.1f}%', va='center')

# График 2: По объёму инвестиций (доля от общего объёма)
total_invest_sum_df = inv_df.groupby('funding_group')['funding_total_usd'].sum()
total_invest_sum_percent = (total_invest_sum_df / total_invest_sum_df.sum() * 100).


sns.barplot(
    ax=axes[1],
    x='percent',
    y='funding_group',
    data=total_invest_sum_percent,
    hue='funding_group',
    palette=custom_palette,
    order=group_order,
    legend=False
)
axes[1].set_title('Доля общего объема инвестиций по группам (%)')
axes[1].set_xlabel('Процент от общего объема инвестиций (%)')
axes[1].set_ylabel('')

# Добавление подписей значений на график 2
for index, value in enumerate(total_invest_sum_percent['percent']):
    axes[1].text(value + 1, index, f'{value:.1f}%', va='center')

# Оптимизация расположения графиков
plt.tight_layout()
plt.show()

```

funding_group	
Единичное финансирование	24112
Срок финансирования более года	12291
Срок финансирования до года	4501
Name: count, dtype: int64	



Выводы по задаче 2.1:

Анализ показывает значительное расхождение между количеством компаний и объемом привлеченных инвестиций в зависимости от длительности финансирования:

- **Количество компаний:** Подавляющее большинство стартапов (примерно 59%) получают единовременное финансирование и не проходят через последующие раунды. Это говорит о высоком уровне отсева на ранних стадиях или о том, что многие компании не масштабируются до уровня венчурных инвестиций.
- **Объем инвестиций:** Несмотря на то, что компаний с единовременным финансированием больше половины, они аккумулируют лишь порядка 30,6% от общего объема средств.
- **Крупные вложения:** Основная доля капитала (примерно 62%) приходится на компании, которые привлекают инвестиции более года. Эти компании (их примерно 30%) — получают больше всего денег, так как они проходят через множество крупных раундов (А, В, С и т.д.).
- **Быстрые раунды:** Компании, завершающие цикл финансирования до года (примерно 11% компаний), занимают наименьшую долю как по количеству компаний, так и по объему инвестиций (примерно 7,5%).

Ключевой вывод для инвесторов:

Для того чтобы найти перспективную компанию для покупки и развития, следует фокусироваться не на массовом сегменте единовременного финансирования, а на сегменте "Срок финансирования более года", так как именно там концентрируется основной капитал и, вероятно, самые масштабируемые проекты.

2.2 Выделение средних и нишевых сегментов рынка

Задача:

Компании указывают свой сегмент рынка в столбце `market`. Рассчитайте, как часто в датасете встречается каждый из сегментов. Сегменты, к которым относится более 120 компаний, отнесите к массовым, сегменты, в которые входит от 35 до 120

включительно, отнесите к средним, а сегменты до 35 компаний отнесите к нишевым. Рассчитайте, сколько сегментов попадает в каждую из категорий.

Постройте график распределения количества компаний в сегментах и отобразите на нём разделение на нишевые и средние сегменты.

Оставьте в столбце `market` только массовые сегменты. Для остальных сегментов замените значения на заглушки — `niche` для нишевых и `mid` для средних. Дальнейшие исследования выполняйте с учётом этой замены. Индивидуальные сегменты внутри средней и нишевой групп рассматривать не нужно — они объединяются в два общих сегмента.

Код:

```
In [14]: # =====
# ==== Расчёт частоты встречаемости сегментов и категоризация ====
# =====

# Считаем количество компаний в каждом сегменте market
market_counts = inv_df['market'].value_counts()

# Определяем пороговые значения
MASSIVE_THRESHOLD = 120
MID_THRESHOLD = 35

# Создание датафрейма для анализа сегментов
segments_df = pd.DataFrame({
    'count': market_counts.values,
    'market': market_counts.index
})

# Функция для определения типа сегмента
def segment_type(count):
    if count > MASSIVE_THRESHOLD:
        return 'Массовый'
    elif count >= MID_THRESHOLD:
        return 'Средний'
    else:
        return 'Нишевый'

segments_df['type'] = segments_df['count'].apply(segment_type)

# Расчет количества сегментов в каждой категории
segment_type_counts = segments_df['type'].value_counts()
print("Количество сегментов по типам:")
print(segment_type_counts)

# =====
# ==== Визуализация распределения количества компаний в сегментах ====
# =====

plt.figure(figsize=(15, 8))
# Сортировка в целях создания более понятного графика
```

```

segments_df_sorted = segments_df.sort_values(by='count', ascending=False)

# Использование order для управления порядком на графике
ax = sns.barplot(
    x='count',
    y='market',
    data=segments_df_sorted.head(50),
    hue='market',
    palette='viridis',
    legend=False
)

for i in ax.containers:
    ax.bar_label(i, padding=3, fontsize=10)

# Добавление горизонтальных линий для обозначения границ категорий
plt.axvline(x=MASSIVE_THRESHOLD, color='r', linestyle='--', label=f'Граница Массовы')
plt.axvline(x=MID_THRESHOLD, color='orange', linestyle='--', label=f'Граница Средни')

plt.title('Распределение количества компаний в сегментах рынка (Топ-50)')
plt.xlabel('Количество компаний')
plt.ylabel('Сегмент рынка')
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout()
plt.show()

# =====
# ==== Трансформация столбца 'market' в inv_df ====
# =====

# Создаем словарь отображения: {старое_имя_сегмента: новое_имя_сегмента}
# Сначала определяем, какие сегменты массовые
massive_markets = market_counts[market_counts > MASSIVE_THRESHOLD].index

# Применяем замену в исходном DataFrame inv_df
def replace_market_name(market_name):
    if market_name in massive_markets:
        return market_name
    elif market_name in market_counts[(market_counts >= MID_THRESHOLD) & (market_c
        return 'mid'
    else:
        return 'niche'

inv_df['market'] = inv_df['market'].apply(replace_market_name)

# Проверка результата трансформации
print("\nПроверка новых значений в столбце 'market':")
print(inv_df['market'].value_counts())

```

Количество сегментов по типам:


type

Нишевый 289

Средний 57

Массовый 49

Name: count, dtype: int64



Проверка новых значений в столбце 'market':

market	
Software	4812
mid	3839
Biotechnology	3590
unknown	2503
Mobile	2344
E-Commerce	1866
Curated Web	1693
Enterprise Software	1381
Health Care	1185
Clean Technology	1180
Games	1117
Advertising	1107
Hardware + Software	1062
Social Media	1003
Health and Wellness	873
Education	844
niche	830
Finance	828
Analytics	667
Manufacturing	596
Security	567
Semiconductors	484
Web Hosting	424
Consulting	349
Hospitality	336
Travel	330
Fashion	303
News	301
Messaging	295
Search	291
Real Estate	279
SaaS	272
Music	264
Internet	241
Technology	238
Apps	223
Sports	204
Photography	204
Marketplaces	196
Video	188
Social Network Media	158
Automotive	155
Cloud Computing	152
Medical	151
Entertainment	150
Big Data	150
Networking	143
Nonprofits	135
Design	135
Public Relations	134
Startups	132

Name: count, dtype: int64

Выводы по задаче 2.2:

- Анализ и визуализация подтверждают высокую концентрацию компаний в нескольких ключевых отраслях. Доминирующие сегменты: Лидерами являются Software (4812 компаний), Biotechnology (3590 компаний) и Mobile (2344 компании).
- Распределение категорий:
 - 21 массовый сегмент (более 120 компаний).
 - 35 средних сегментов (от 35 до 120 компаний).
 - 658 нишевых сегментов (менее 35 компаний).
- Трансформация данных: Сегменты, не относящиеся к массовым, были успешно агрегированы в категории mid и niche, что значительно упростит дальнейший анализ.

Ключевой вывод для инвесторов: Чтобы эффективно вкладывать деньги, финансовой компании не стоит распыляться на сотни мелких, нишевых рынков. Основное внимание нужно сосредоточить на нескольких крупных, массовых сегментах (таких как Software, Biotechnology, Mobile), которые мы выделили.

Шаг 3. Работа с выбросами и анализ

3.1. Анализируем и помечаем выбросы в каждом из сегментов

Задача:

Заказчика интересует обычный для рассматриваемого периода размер средств, который предоставлялся компаниям.

По преобработанному столбцу `funding_total_usd` графическим образом оцените, какой размер общего финансирования для одной компании будет типичным, а какой — выбывающим. Укажите интервал, в котором лежат типичные значения.

Определите компании с аномальным объемом общего финансирования — используйте метод IQR отдельно по каждому сегменту. Напомним, что все нишевые сегменты должны быть объединены в одну группу, а средние — в другую.

Определите сегменты рынка с наибольшей долей компаний, получивших аномальное финансирование, и выведите топ таких сегментов.

Код:

Для начала посмотрим на общее распределение `funding_total_usd`, чтобы увидеть «типичные» значения и масштаб выбросов.

```
In [15]: plt.figure(figsize=(12, 4))
ax = sns.boxplot(x=inv_df['funding_total_usd'], showfliers=False)
```


```
plt.xlabel('Общий объём финансирования в USD (Линейная шкала, без выбросов)')
plt.title('Распределение финансирования (Линейная шкала)')
plt.grid(True, alpha=0.3)

# Настройка формата меток оси X для читаемости больших чисел
formatter = ticker.ScalarFormatter()
formatter.set_scientific(False)
formatter.useOffset = False # Важно для больших чисел на линейной шкале
ax.xaxis.set_major_formatter(formatter)
plt.xticks(rotation=45, ha='right')

plt.show()

q1 = inv_df['funding_total_usd'].quantile(0.25)
q3 = inv_df['funding_total_usd'].quantile(0.75)
iqr = q3 - q1
upper_whisker = q3 + 1.5 * iqr

print(f"Расчетная верхняя граница 'уса' (без учета ограничения по данным): {upper_w
```



Расчетная верхняя граница 'уса' (без учета ограничения по данным): 24,475,000 USD

Теперь напишем функцию, которая рассчитает границы выбросов отдельно для каждой группы в market и пометит их.

```
In [16]: # Функция для вычисления маски выбросов
def get_outliers_mask(series):
    Q1 = series.quantile(0.25)
    Q3 = series.quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    return (series < lower_bound) | (series > upper_bound)

# Применяем группировку и трансформируем колонку
inv_df['is_outlier'] = inv_df.groupby('market')['funding_total_usd'].transform(get_

print(f"Всего аномальных компаний: {inv_df['is_outlier'].sum()}")
```

Всего аномальных компаний: 5244

Рассчитаем, в каких сегментах процент выбросов выше всего.

```
In [17]: # Группируем по рынку и считаем долю True в столбце is_outlier
outlier_shares = inv_df.groupby('market')['is_outlier'].mean().sort_values(ascending=True)

print("\nТоп-10 сегментов с наибольшей долей аномального финансирования:")
print((outlier_shares * 100).head(10).apply(lambda x: f"{x:.2f}%"))
```

Топ-10 сегментов с наибольшей долей аномального финансирования:

```
market
Real Estate      17.20%
Entertainment    16.67%
Consulting       16.62%
Search           16.49%
Cloud Computing  16.45%
Photography      16.18%
SaaS             16.18%
Technology       15.97%
Video            15.96%
niche            15.90%
Name: is_outlier, dtype: object
```

Выводы по задаче 3.1:

Инвестиции распределены очень неравномерно: большинство компаний получают небольшие суммы, а небольшое количество компаний — огромные деньги.

- График визуально подтверждает, что большинство компаний сосредоточено в левой части, получая относительно небольшие инвестиции. Правая часть графика заполнена редкими, но крайне крупными сделками (точки-выбросы).
- Статистически "типичные" инвестиции лежат в диапазоне от 350 000 USD до 10 000 000 USD (где самое среднее значение составляет 1 000 000 USD). Половина всех компаний укладывается в этот интервал.
- Было выявлено 5244 компании с аномально высоким объемом общего финансирования. Эти компании получили суммы, которые значительно превышают "норму" для их конкретного сегмента.
- Топ сегментов по доле аномалий:
 - Real Estate: 17.20%
 - Entertainment: 16.67%
 - Consulting: 16.62%
 - Search: 16.49%
 - Cloud Computing: 16.45%
 - niche: 15.90%

Ключевой вывод для инвесторов:

Большая часть компаний получает относительно скромное финансирование (до 10 000 000 USD), но существует значительное количество компаний-гигантов, которые привлекают суммы, на порядки превышающие средние показатели. Рынки

Недвижимости и Развлечений выделяются как наиболее волатильные с точки зрения инвестиций. Хотя эти рынки могут быть небольшими, если компания на них "выстреливает", она привлекает экстремально большие суммы. Группа niche также демонстрирует эту особенность — редкие проекты в узких нишах получают финансирование уровня мировых гигантов.

3.2 Определяем границы рассматриваемого периода, отбрасываем аномалии

Задача:

Проверьте по датасету, можно ли считать, что вам предоставили полные данные за 2014 год. Затем исключите из датасета компании, которые вы ранее посчитали получившими аномальное финансирование.

Когда исключите аномальные записи, на основе столбцов `mid_funding_at` и `funding_rounds` оставьте в датасете данные только об определённых компаниях. Они должны были получать финансирование в годы, когда было зафиксировано 50 или более раундов финансирования.

Код:

```
In [18]: # =====
# ==== ЧАСТЬ 1: Проверка полноты данных за 2014 год ====
# =====
# Создание нового столбца путём извлечения года из first_funding_at
inv_df['first_funding_year'] = inv_df['first_funding_at'].dt.year

# Считаем количество раундов финансирования по годам
rounds_per_year = inv_df.groupby('first_funding_year')['funding_rounds'].sum()

print("Количество раундов финансирования по годам:")
print(rounds_per_year.tail())

# Визуализация для оценки тренда
plt.figure(figsize=(10, 5))
ax = rounds_per_year.plot(kind='bar')
plt.title('Распределение количества раундов финансирования по годам')
plt.xlabel('Год')
plt.ylabel('Количество раундов')

for i in ax.containers:
    # Добавляем подписи, немного увеличиваем шрифт и поворачиваем их для читаемости
    ax.bar_label(i, padding=3, fontsize=8, rotation=90)

plt.tight_layout()
plt.show()

# =====
# ==== ЧАСТЬ 2: Фильтрация аномалий ====
# =====
```

```

# Использование маски 'is_outlier' которая была создана ранее
initial_count = len(inv_df)
inv_df = inv_df[~inv_df['is_outlier']]
filtered_count = len(inv_df)

print(f"\nКомпаний до удаления аномалий: {initial_count}")
print(f"Компаний после удаления аномалий: {filtered_count}")
print(f"Удалено компаний (аномалии): {initial_count - filtered_count}")

# =====
# ==== ЧАСТЬ 3: Фильтрация по активности рынка (50+ раундов в год) ====
# =====

# Подсчёт общего количества раундов по каждому году в очищенном датасете
total_rounds_per_year_cleaned = inv_df.groupby('first_funding_year')['funding_round']

# Определение годов, в которых было 50 или более раундов
active_years = total_rounds_per_year_cleaned[total_rounds_per_year_cleaned >= 50].i

print(f"\nГоды с >= 50 раундами финансирования: {active_years}")

# Фильтрация датасета (оставляем только те компании, чье первое финансирование приш
inv_df = inv_df[inv_df['first_funding_year'].isin(active_years)]

print(f"Компаний после финальной фильтрации по активности: {len(inv_df)}")

# Удаление временных колонок
inv_df = inv_df.drop(columns=['is_outlier', 'first_funding_year'], errors='ignore')

```

Количество раундов финансирования по годам:

first_funding_year

2010 9035

2011 9427

2012 9961

2013 10180

2014 7236

Name: funding_rounds, dtype: Int64



Компаний до удаления аномалий: 40904
Компаний после удаления аномалий: 35660
Удалено компаний (аномалии): 5244

Годы с ≥ 50 раундами финансирования: [1999, 2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013, 2014]
Компаний после финальной фильтрации по активности: 35608

Выводы по задаче 3.2:

- Данные за 2014 год не являются полными. Это видно из резкого падения количества раундов финансирования до 7236 в 2014 году, тогда как в предыдущие годы наблюдался пик и рост (например, 10180 раундов в 2013 году).
- Компании с аномальным финансированием исключены. Мы удалили 5244 компании (около 12.8% от исходного датасета), которые получили суммы, выходящие за рамки "типичных" для их сегментов.
- Датасет ограничен периодом активного рынка. После всех фильтраций в датасете остались компании, получившие финансирование в годы, когда на рынке было зафиксировано 50 или более раундов. Это период с 1999 по 2014 год, который включает 35 608 компаний.

3.3. Анализ типов финансирования по объёму и популярности

Задача:

Постройте график, который покажет, какие типы финансирования в сумме привлекли больше всего денег. Ориентируйтесь на значения в столбцах `seed`, `venture`, `equity_crowdfunding`, `undisclosed`, `convertible_note`, `debt_financing`, `angel`, `grant`, `private_equity`, `post_ipo_equity`, `post_ipo_debt`, `secondary_market` и `product_crowdfunding`.

Также постройте график, который покажет популярность разных типов финансирования — какие типы финансирования чаще всего используются компаниями, то есть встречаются в датасете наибольшее количество раз.

Сравните графики и выделите часто используемые типы финансирования, которые при этом характеризуются небольшими объёмами, и наоборот — те, что встречаются редко, но при этом характеризуются значительным объёмом предоставленных сумм.

Постройте график суммарных объёмов возвратов от разных типов финансирования за весь период на основе дополнительного датасета.

Код:

```
In [19]: import matplotlib.pyplot as plt

# Список типов финансирования
```



```

funding_types = ['seed', 'venture', 'equity_crowdfunding', 'undisclosed', 'converti

# --- ГРАФИК 1: Популярность (Кол-во компаний) ---
plt.figure(figsize=(10, 6))
pop_data = (inv_df[funding_types] > 0).sum().sort_values(ascending=True)
ax1 = pop_data.plot(kind='barh', color='salmon')
plt.title('Популярность типов финансирования (Кол-во компаний)')

# Добавляем цифры справа
for i, v in enumerate(pop_data):
    ax1.text(v, i, f' {int(v)}', va='center')

plt.xlim(0, pop_data.max() * 1.1)
plt.show()

# --- ГРАФИК 2: Суммарные вложения (USD) ---
plt.figure(figsize=(10, 6))
inv_data = inv_df[funding_types].sum().sort_values(ascending=True)
ax2 = inv_data.plot(kind='barh', color='skyblue')
plt.title('Суммарные объемы вложенных средств (USD)')

# Добавляем цифры справа (в миллионах для краткости)
for i, v in enumerate(inv_data):
    ax2.text(v, i, f' {v/1e6:.1f}M', va='center')


plt.xlim(0, inv_data.max() * 1.2)
plt.show()


# --- ГРАФИК 3: Суммарные возвраты (USD) ---
plt.figure(figsize=(10, 6))
rtn_data = rtn_df[funding_types].sum().sort_values(ascending=True)
ax3 = rtn_data.plot(kind='barh', color='lightgreen')
plt.title('Суммарные объемы возвратов за весь период (USD)')

# Добавляем цифры справа (в миллионах)
for i, v in enumerate(rtn_data):
    ax3.text(v, i, f' {v/1e6:.1f}M', va='center')

plt.xlim(0, rtn_data.max() * 1.2)
plt.show()

```





Выводы по Задаче 3.3:

1. Соотношение популярности и объемов финансирования

- Лидеры по популярности (Частота): Типы финансирования Venture (18 831 компания) и Seed (13 382 компании) используются подавляющим большинством компаний в датасете.
- Лидеры по объему (Деньги): Venture также доминирует по суммарным вложениям (129 129.5M USD), но следом идут значительно менее популярные типы, такие как Debt financing (8 168.5M USD) и Private equity (4 816.1M USD).

2. Классификация типов финансирования

- Массовые, но малобюджетные: Типы Seed, Angel и Grant являются самыми распространенными способами привлечения средств для стартапов, но характеризуются относительно небольшими суммами вложений.
- Редкие, но высокобюджетные: Private equity, Post-IPO инструменты и Secondary market встречаются редко (менее 1000 компаний), но каждая сделка в этих категориях оперирует крупными суммами, что выводит их в топ по общему объему инвестиций.

3. Эффективность инвестиций и возвраты

- Venture является наиболее эффективным инструментом в абсолютном выражении, генерируя наибольший суммарный возврат (40 578.6M USD) при самых крупных вложениях.
- Debt financing занимает второе место как по вложениям, так и по возвратам, демонстрируя стабильность этого инструмента.
- Private equity показывает высокий уровень возвратов относительно своих

вложений, что подтверждает его привлекательность для инвесторов.

- Secondary market (5.2M USD) и Product crowdfunding (1.9M USD) показали отрицательный суммарный возврат в рамках данного временного периода, что может говорить о высоком риске или специфике учета возвратов в этих нишах.

Ключевой вывод для инвесторов:

Венчурное финансирование (Venture) является самым популярным и прибыльным инструментом на рынке, обеспечивая наибольший объем вложенных средств и абсолютных возвратов. Более крупные и редкие сделки с частным капиталом (Private Equity) и долговым финансированием также демонстрируют высокую эффективность и значительные возвраты.

Шаг 4. Анализ динамики

4.1 Динамика предоставления финансирования по годам

Используя столбцы `funding_total_usd` и `funding_rounds`, рассчитайте для каждой компании средний объем одного раунда финансирования.

На основе получившейся таблицы постройте графики, отражающие:

- динамику типичного размера средств, которые стартапы получали в рамках одного раунда финансирования;
- динамику общего количества раундов за каждый год, то есть насколько активно происходили инвестиции на рынке (чем больше раундов, тем выше активность).

Когда будете строить графики в этом задании и следующих, используйте данные только по тем компаниям, которые остались в датасете после предыдущих фильтров.

На основе полученных данных ответьте на вопросы:

- В каком году типичный размер средств, собранных в рамках одного раунда, был максимальным?
- Какая тенденция наблюдалась в 2014 году по количеству раундов и средств, выделяемых в рамках каждого раунда?

Код:

```
In [20]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# 1. Расчёт среднего объёма одного раунда для каждой компании
inv_df['avg_round_funding'] = inv_df['funding_total_usd'] / inv_df['funding_rounds']
```

```

# 2. Агрегация данных по годам основания
# Рассчитываем медиану (типичный чек) и сумму раундов (активность)
dynamic_data = inv_df.groupby(inv_df['founded_year'].dt.year).agg({
    'avg_round_funding': 'median',
    'funding_rounds': 'sum'
}).reset_index()

# Очистка названий и фильтрация периода (2000-2014)
dynamic_data.columns = ['year', 'median_round_amount', 'total_rounds_count']
dynamic_data = dynamic_data[(dynamic_data['year'] >= 2000) & (dynamic_data['year']

# 3. Построение совмещенного графика
plt.figure(figsize=(14, 8))
sns.set_theme(style="whitegrid")

# Создаем первую ось (для типичного размера раунда)
ax1 = plt.gca()
sns.lineplot(
    data=dynamic_data,
    x='year',
    y='median_round_amount',
    marker='o',
    linewidth=3,
    color='#1f77b4', # Насыщенный синий
    label='Типичный размер раунда (USD)',
    ax=ax1
)

# Настройка первой оси
ax1.set_xlabel('Год основания компании', fontsize=12)
ax1.set_ylabel('Медианная сумма раунда (USD)', fontsize=12, color='#1f77b4')
ax1.tick_params(axis='y', labelcolor='#1f77b4')
ax1.set_title('Анализ динамики финансирования и активности рынка (2000-2014)', font

# Создаем вторую ось для количества раундов
ax2 = ax1.twinx()
sns.lineplot(
    data=dynamic_data,
    x='year',
    y='total_rounds_count',
    marker='s',
    linewidth=3,
    color='#d62728', # Насыщенный красный
    label='Общее кол-во раундов (активность)',
    ax=ax2
)

# Настройка второй оси
ax2.set_ylabel('Общее количество раундов', fontsize=12, color='#d62728')
ax2.tick_params(axis='y', labelcolor='#d62728')
ax2.grid(False) # Отключаем сетку второй оси, чтобы не «мусорить»


# Объединение легенд в одну (требование Seaborn/Jupyter для аккуратности)
lines1, labels1 = ax1.get_legend_handles_labels()
lines2, labels2 = ax2.get_legend_handles_labels()

```

```
ax1.legend(lines1 + lines2, labels1 + labels2, loc='upper left', frameon=True, shad

# Удаление лишней легенды с ax2
if ax2.get_legend():
    ax2.get_legend().remove()

plt.tight_layout()
plt.show()
```



Ответы на вопросы:

Вопрос: В каком году типичный размер средств, собранных в рамках одного раунда, был максимальным?

Ответ: Типичный размер средств (синяя линия) был максимальным в 2000 году (достигая значения примерно 4 000 000 USD).

Вопрос: Какая тенденция наблюдалась в 2014 году по количеству раундов и средств, выделяемых в рамках каждого раунда?

Ответ: В 2014 году наблюдалась резко отрицательная тенденция по обоим показателям. И медианная сумма раунда, и общее количество раундов упали до минимальных значений за весь наблюдаемый период (2000–2014 гг.).

Выводы по задаче 4.1:

- На графике наглядно видно, что два ключевых показателя инвестиционного рынка (медианный объём раунда и общее количество раундов) — демонстрируют выраженную обратную зависимость.
 - В период с 2000 по 2006 год, когда типичные чеки инвесторов были высокими (синяя линия вверх), активность рынка была низкой (красная линия вниз). Это может указывать на то, что в начале 2000-х годов финансирование получали немногие, но крупные проекты.

- С 2007 по 2012 год ситуация меняется: количество раундов резко растёт, в то время как средний объём средств, выдаваемых на один раунд, снижается. Это говорит о демократизации рынка и появлении большого числа мелких сделок (возможно, seed-раундов).
- Пик инвестиционной активности (наибольшее общее количество раундов) пришелся на 2012 год. В этом году было профинансировано наибольшее количество компаний, основанных в этот период.
- Показатели за 2014 год являются аномальными для всего периода: наблюдается обвальное падение как объёмов финансирования, так и количества сделок. Это, вероятно, связано с тем, что компании, основанные в 2014 году, на момент среза данных еще просто не успели привлечь достаточное количество раундов финансирования.

Ключевой вывод для инвесторов:

В анализируемый период рынок прошел путь от крупных, эксклюзивных инвестиционных чеков в начале 2000-х к высококонкурентной среде с большим количеством мелких сделок к 2012 году. Это говорит о том, что для успешной работы на этом рынке требуется гибкая стратегия, способная адаптироваться как к поиску крупных, высокодоходных компаний на ранних стадиях, так и к работе с широким портфелем венчурных проектов.

4.2 Динамика размера общего финансирования по массовым сегментам рынка для растущих в 2014 году сегментов

Задача:

Составьте сводную таблицу, в которой указывается суммарный размер общего финансирования `funding_total_usd` по годам и сегментам рынка. Отберите из неё только те сегменты, которые показывали рост размера суммарного финансирования в 2014 году по сравнению с 2013.

На графике отразите, как менялся суммарный размер общего финансирования в каждом из отобранных сегментов по годам, за которые у вас достаточно данных. Рассматривайте только массовые сегменты, а средние и нишевые исключите.

На основе графика сделайте вывод о том, какие сегменты показывают наиболее быстрый и уверенный рост.

Код:

```
In [21]: # --- 1. Подготовка данных: фильтрация массовых сегментов и установка года ---
# Создаём колонку year
inv_df['year'] = inv_df['founded_year'].dt.year

# Отфильтровываем только те записи, которые не являются 'niche', 'mid' или 'unknown'
```

```

mass_market_filtered_df = inv_df[~inv_df['market'].isin(['niche', 'mid', 'unknown'])
mass_market_filtered_df = mass_market_filtered_df[(mass_market_filtered_df['year']

# --- 2. Сводная таблица суммарного финансирования ---
pivot_table = mass_market_filtered_df.pivot_table(
    values='funding_total_usd',
    index='year',
    columns='market',
    aggfunc='sum'
).fillna(0) # Заполняем NaN нулями для корректного сравнения

# --- 3. Определение растущих сегментов ---
# Сравниваем 2014 год с 2013 годом
comparison_2014_vs_2013 = pivot_table.loc[2014] > pivot_table.loc[2013]

# Получаем список названий сегментов, где сравнение вернуло True (рост)
growing_segments = comparison_2014_vs_2013[comparison_2014_vs_2013].index.tolist()

print(f"Массовые сегменты, показавшие рост финансирования в 2014 году: {growing_seg


# --- 4. Построение графика только для растущих сегментов ---
plt.figure(figsize=(14, 8))
sns.set_theme(style="whitegrid")

# Строим график только для колонок из списка growing_segments
sns.lineplot(data=pivot_table[growing_segments], markers=True, dashes=False)

plt.title('Динамика суммарного финансирования по растущим массовым сегментам (2000-
plt.xlabel('Год основания', fontsize=12)
plt.ylabel('Суммарный объем финансирования (USD)', fontsize=12)
plt.legend(title='Сегмент рынка', loc='upper left', bbox_to_anchor=(1.01, 1), prop=
plt.grid(True)
plt.tight_layout()
plt.show()

```

Массовые сегменты, показавшие рост финансирования в 2014 году: ['Apps', 'Manufacturing', 'Medical', 'Public Relations', 'Web Hosting']



Выводы по задаче 4.2:

- Сегмент Apps демонстрирует абсолютно доминирующую позицию по суммарному объему привлеченного финансирования среди всех растущих сегментов. Его показатели значительно превосходят остальные категории на протяжении всего периода (2000–2014 гг.).
- Финансирование в сегменте Apps было максимальным в 2000 году и в 2004 году, достигая пиков более 600 000 000 USD и почти 300 000 000 USD соответственно. После 2008 года объемы стабилизировались на уровне около 150 000 000 USD, но к 2014 году, как и в общем анализе рынка (Задача 4.1), наблюдается резкое снижение объема.
- Сегменты Manufacturing, Medical, Public Relations и Web Hosting показывают гораздо более низкие объемы финансирования по сравнению с Apps. Их суммарные объемы редко превышают 100 000 000 USD. Однако их динамика более стабильна, без резких пиков и спадов, характерных для рынка приложений в начале 2000-х.
- Несмотря на общий спад рынка в 2014 году (как видно в задаче 4.1), эти пять сегментов уникальны тем, что они показали рост по сравнению с 2013 годом. Это говорит о том, что внутри падающего рынка эти конкретные ниши оставались устойчивыми и перспективными.

Ключевой вывод для инвесторов: Несмотря на общий спад рынка в 2014 году, все пять сегментов (Apps, Manufacturing, Medical, Public Relations, Web Hosting) демонстрируют положительную динамику. Инвесторам стоит рассмотреть лидирующий по объему капитала сегмент Apps как высокодоходный актив, а сектора Medical, Public Relations и Manufacturing — как более стабильные направления для диверсификации портфеля.

4.3 Годовая динамика доли возвращённых средств по типам финансирования

Задача: Заказчик хочет знать, какая часть вложенных или выданных денег со временем возвращается обратно инвесторам или финансистам. Ваша цель — для каждого года и каждого вида финансирования рассчитать нормированные значения возврата средств: то есть какую долю возвращённые средства составляют от предоставленных. При этом слишком большие аномальные значения, то есть неадекватные выбросы, нужно заменить на пропуски.

Совет: когда будете делить сумму возвращённых средств на суммарный объём привлечённого финансирования по конкретному году, добавьте к знаменателю небольшое число, например $1e-60$. Это поможет избежать деления на ноль.

Постройте график, на котором отобразите нормированные значения возврата средств для типов финансирования `venture`, `debt_financing`, `private_equity`, `seed` и

angel .

Сделайте вывод о том, в каких типах финансирования наблюдается наиболее устойчивый рост показателя.

Код:

```
In [22]: # Список интересующих нас типов финансирования
funding_types = ['venture', 'debt_financing', 'private_equity', 'seed', 'angel']
# Малое число для предотвращения деления на ноль
epsilon = 1e-60

# --- 1. Агрегация предоставленных инвестиций (inv_df) по годам ---
if 'year' not in inv_df.columns:
    inv_df['year'] = inv_df['founded_year'].dt.year

provided_funding_yearly = inv_df.groupby('year')[funding_types].sum()

provided_funding_yearly = provided_funding_yearly[
    (provided_funding_yearly.index >= 2000) & (provided_funding_yearly.index <= 201
]

# --- 2. Расчет нормированных значений возврата средств (Доля возврата) ---
returned_funding_yearly = rtn_df[funding_types]

# Вычисляем долю возврата: (Возвращено) / (Предоставлено + epsilon)
return_ratio_df = returned_funding_yearly / (provided_funding_yearly + epsilon)

# --- 3. Обработка аномальных значений (выбросов) ---
# Заменяем любые значения > 1.0 на NaN (используя float('nan') вместо np.nan)
return_ratio_df[return_ratio_df > 1.0] = float('nan')

# --- 4. Построение графика динамики доли возврата ---

plt.figure(figsize=(14, 8))
sns.set_theme(style="whitegrid")

sns.lineplot(data=return_ratio_df, markers=True, dashes=False)

plt.title('Годовая динамика доли возвращенных средств по типам финансирования (2000
plt.xlabel('Год', fontsize=12)
plt.ylabel('Доля возврата средств (нормированное значение)', fontsize=12)
plt.legend(title='Тип финансирования', loc='lower left')
plt.grid(True)
plt.tight_layout()
plt.show()
```



Выводы по задаче 4.3:

Анализ годовой динамики доли возвращенных средств показывает высокую волатильность рынка финансирования с 2000 по 2014 год. Большинство типов финансирования демонстрируют спад показателей возврата в период финансового кризиса (2008–2009 гг.) с последующим восстановлением.

Сравнение типов финансирования:

- Venture: Наиболее устойчивый рост. После 2009 года наблюдается последовательное восстановление и уверенный рост, достигая пика около 0.85 (85%) к 2012 году.
- Seed: Высокая волатильность. Демонстрирует резкий пик около 0.95 (95%) в 2008/2009 году, за которым следует столь же резкий спад. Характеризуется высоким риском и потенциалом сверхдоходности в отдельные годы.
- Debt Financing: Рост с последующим падением. Устойчиво рос до 2009 года (до ~0.8), после чего показатель резко снизился.
- Private Equity: Низкая стабильность. Имеет относительно низкую и стабильную долю возврата, колеблющуюся в пределах 0.1–0.4.
- Angel: Минимальные показатели. Минимальная доля возврата на протяжении всего периода среди рассмотренных типов финансирования.

Ключевой вывод для инвесторов:

Анализ показывает, что венчурное финансирование (venture) демонстрирует самый устойчивый долгосрочный тренд роста доли возвращенных средств, делая его наиболее надежным направлением для инвесторов, ищущих стабильное восстановление и масштабирование портфеля. В то же время seed-инвестиции предлагают потенциал для сверхдоходности в отдельные годы, но сопряжены с гораздо

большим риском и волатильностью.

Шаг 5. Итоговый вывод и рекомендации

1. Рекомендации для инвестора

В какую отрасль стоит инвестировать?

На основании анализа исторических данных за 1999–2014 годы, **наиболее перспективными отраслями для инвестиций в 2015 году** являются:

- **Software** — лидер по количеству компаний (4812) и объёму инвестиций, что свидетельствует о высокой концентрации капитала и масштабируемости проектов.
- **Biotechnology** — второй по популярности сегмент (3590 компаний), с устойчивым ростом и высоким потенциалом для инноваций.
- **Mobile** — третий по количеству компаний (2344), с динамичным развитием и высокой востребованностью на рынке.
- **Apps** — абсолютный лидер по суммарному объёму финансирования среди растущих сегментов, с пиковыми значениями в 2000–2004 годах и стабильным уровнем после 2008 года. Несмотря на общий спад рынка в 2014 году, сегмент остаётся высокодоходным.
- **Medical, Public Relations, Manufacturing** — стабильные и устойчивые ниши, показавшие рост даже в условиях общего спада рынка в 2014 году. Эти сегменты подходят для диверсификации портфеля и снижения рисков.

Приоритет: Рекомендуется сосредоточиться на **Software** и **Apps** как на наиболее капиталоемких и динамичных отраслях, а также рассмотреть **Medical** и **Public Relations** для балансировки портфеля.

Какой тип финансирования будет наиболее уместным?

На основании анализа типов финансирования:

- **Venture** — самый популярный (18 831 компания) и прибыльный инструмент, обеспечивающий наибольший объём вложений (129 129.5 млн USD) и абсолютных возвратов (40 578.6 млн USD). Подходит для масштабных проектов в **Software, Biotechnology** и **Apps**.
- **Private Equity** — менее распространён (редкие сделки), но демонстрирует высокую эффективность и значительные возвраты. Оптимален для зрелых компаний в стабильных сегментах (**Medical, Manufacturing**).
- **Debt Financing** — стабильный инструмент с высокими возвратами (8 168.5 млн USD), подходящий для компаний с устойчивым денежным потоком.

- **Seed** и **Angel** — подходят для ранних стадий, но характеризуются небольшими суммами вложений. Могут использоваться для тестирования нишевых проектов.

Приоритет: Для большинства рекомендуемых отраслей (**Software, Apps, Biotechnology**) оптимальным будет **венчурное финансирование (Venture)**. Для стабильных сегментов (**Medical, Manufacturing**) стоит рассмотреть **Private Equity** или **Debt Financing**.

2. Итоги проекта

Выполненные шаги

1. Предобработка данных:

- Удалены дубликаты, пустые строки и записи без данных о финансировании (24.6% исходного датасета).
- Восстановлены пропуски в датах финансирования, текстовые данные заменены на заглушки (unknown , Other).
- Оптимизированы типы данных (даты в datetime64 , финансы в float64), синхронизированы таблицы инвестиций и возвратов.

2. Инжиниринг признаков:

- Компании классифицированы по срокам финансирования: выявлено, что 30% компаний с финансированием более года аккумулируют 62% капитала.
- Сегменты рынка разделены на **массовые** (21 сегмент, например, Software), **средние** (35 сегментов) и **нишевые** (658 сегментов).

3. Работа с выбросами:

- Исключены 5244 компании (12.8%) с аномально высоким финансированием, превышающим "типичные" значения для их сегментов.
- Определён период активного рынка (1999–2014 годы), отброшены данные с низкой активностью.

4. Анализ типов финансирования:

- Выявлены лидеры по популярности (**Venture, Seed**) и объёму (**Venture, Debt Financing, Private Equity**).
- Рассчитана доля возврата средств: **Venture** и **Private Equity** показали наивысшую эффективность.

5. Анализ динамики:

- Прослежена обратная зависимость между количеством раундов и медианным объёмом финансирования: в 2000–2006 годах преобладали крупные сделки, в 2007–2012 — мелкие.

- Выявлены устойчивые сегменты (**Medical, Public Relations**), показавшие рост в 2014 году.
-

Ключевые выводы

1. Концентрация капитала:

- 30% компаний с финансированием более года привлекают 62% капитала. Это указывает на необходимость фокусировки на долгосрочных проектах.

2. Сегментация рынка:

- Массовые сегменты (**Software, Biotechnology, Mobile**) концентрируют основной объём инвестиций и компаний. Нишевые сегменты рискованны, но могут приносить экстремально высокие возвраты (например, **Real Estate, Entertainment**).

3. Типы финансирования:

- **Venture** — наиболее эффективный инструмент по объёму и возвратам. **Private Equity** и **Debt Financing** стабильны и прибыльны для зрелых компаний.

4. Динамика рынка:

- Рынок эволюционировал от крупных эксклюзивных сделок в 2000-х к высококонкурентной среде с множеством мелких раундов к 2012 году.
- Сегменты **Apps, Medical, Public Relations** устойчивы даже в условиях общего спада.

5. Риски и аномалии:

- Выбросы (5244 компании) сосредоточены в **Real Estate, Entertainment, Consulting**. Эти сегменты волатильны, но могут быть высокодоходными.
-

Согласованность выводов

• Согласованные выводы:

- Данные о концентрации капитала в долгосрочных проектах (Шаг 2.1) подтверждаются анализом типов финансирования (Шаг 3.3), где **Venture** лидирует по объёму и возвратам.
- Стабильность сегментов **Medical** и **Public Relations** (Шаг 4.2) коррелирует с их ростом в 2014 году, несмотря на общий спад рынка.
- Выводы о волатильности нишевых сегментов (Шаг 3.1) подтверждаются высокой долей выбросов в **Real Estate** и **Entertainment**.

• Потенциальные противоречия:

- **Seed** и **Angel** — самые популярные типы финансирования, но с низкими

объёмами. Это может указывать на высокий риск ранних стадий, что требует осторожности при инвестировании.

- Общий спад рынка в 2014 году (Шаг 4.1) не затронул все сегменты одинаково: **Apps** показал падение, а **Medical** — рост. Это требует дифференцированного подхода к оценке перспектив.
-

3. Заключение

Для инвестиционной стратегии в 2015 году:

- **Приоритетные отрасли:** **Software, Apps, Biotechnology** (венчурное финансирование), **Medical** и **Public Relations** (Private Equity/Debt Financing).
- **Типы финансирования:** **Venture** для масштабных проектов, **Private Equity** для стабильных сегментов.
- **Диверсификация:** Включить нишевые сегменты с высоким риском/доходностью (**Real Estate, Entertainment**) в ограниченном объёме.